

PHÂN LOẠI CIFAR-10 BẰNG ĐẶC TRƯNG THỊ GIÁC VÀ HỌC MÁY TRUYỀN THỐNG

Hồ Võ Hoàng Duy - 25C01002

Ngày 13 tháng 9 năm 2026

Tóm tắt

Báo cáo trình bày một quy trình phân loại ảnh CIFAR-10 bằng các phương pháp thị giác máy tính truyền thống. Các thành phần chính gồm ba loại đặc trưng (Pixel thô, HOG, SIFT) kết hợp với hai mô hình phân lớp (SVM tuyến tính và Random Forest); toàn bộ được cài đặt từ đầu với NumPy làm thư viện tính toán nền tảng. Trên 10.000 ảnh kiểm tra, HOG-SVM đạt độ chính xác cao nhất. Kết quả được phân tích bằng ma trận nhầm lẫn, chỉ số theo lớp và đường hội tụ loss.

1 Giới thiệu

Báo cáo tập trung vào bài toán phân loại ảnh trên bộ dữ liệu CIFAR-10. Bộ dữ liệu gồm 60.000 ảnh màu kích thước 32×32 , chia đều thành 10 lớp [3]. Mỗi ảnh có độ phân giải thấp và chứa nhiều biến đổi về góc nhìn, nền hoặc hình dáng vật thể. Vì vậy, đây là dữ liệu phù hợp để đánh giá các đặc trưng thị giác truyền thống trong điều kiện thông tin ảnh bị hạn chế.

Mục tiêu của đồ án là xây dựng đầy đủ các bước từ đọc dữ liệu, trích xuất đặc trưng, huấn luyện mô hình đến suy luận trên ảnh mới. Các thuật toán chính được cài đặt từ đầu, không sử dụng các thư viện có sẵn. Pixel thô được dùng làm mốc so sánh; HOG và SIFT là hai cách biểu diễn đặc trưng; SVM tuyến tính và Random Forest đảm nhiệm phân lớp.

Trong phần thực nghiệm, báo cáo tiến hành so sánh kết quả giữa các phương pháp trên toàn bộ dữ liệu CIFAR-10 để đánh giá ưu nhược điểm của từng cặp đặc trưng – mô hình.

2 Dữ liệu và tiền xử lý

CIFAR-10 cung cấp 50.000 ảnh huấn luyện và 10.000 ảnh kiểm tra gốc [3]. Toàn bộ 60.000 ảnh này đều được sử dụng trong thử nghiệm. Cụ thể, từ 50.000 ảnh gốc ban đầu, chương trình chia theo tỷ lệ 90:10, giữ lại 45.000 ảnh cho tập huấn luyện chính và trích ra 5.000 ảnh (10%) làm tập kiểm định (validation). Phép chia phân tầng giữ nguyên tỉ lệ lớp trong từng phần. Tập kiểm tra (test) giữ nguyên trọn vẹn 10.000 ảnh và chỉ được sử dụng sau khi cấu hình đã được xác định. Bảng 1 trình bày số lượng và vai trò của từng tập.

Bảng 1: Phân chia dữ liệu trong thí nghiệm đầy đủ.

Tập	Số ảnh	Số ảnh/lớp	Vai trò
Huấn luyện	45.000	4.500	Học bộ chuẩn hóa và mô hình
Kiểm định	5.000	500	Kiểm tra cấu hình
Kiểm tra	10.000	1.000	Đánh giá cuối

Ảnh được chuyển đổi sang số thực trong khoảng $[0, 1]$. HOG và SIFT dùng ảnh xám, $I = 0.299R + 0.587G + 0.114B$. Mỗi chiều đặc trưng d được chuẩn hóa như sau:

$$\hat{x}_{id} = \frac{x_{id} - \mu_d^{\text{train}}}{\sigma_d^{\text{train}} + \epsilon}. \quad (1)$$

Trung bình và độ lệch chuẩn chỉ được ước lượng trên tập huấn luyện. Các tham số sau đó được giữ cố định khi xử lý tập kiểm định và tập kiểm tra. Quy trình này ngăn rò rỉ dữ liệu từ bước đánh giá vào bước huấn luyện.

3 Phương pháp

3.1 Histogram of Oriented Gradients

HOG mô tả hình dạng của vật thể bằng phân bố hướng biến thiên cường độ sáng trong từng vùng nhỏ [2]. Phương pháp không so sánh trực tiếp giá trị của từng pixel. Thay vào đó, HOG quan sát vị trí xuất hiện của các cạnh và hướng của chúng. Cách

biểu diễn này phù hợp với CIFAR-10 vì đường viền của cánh máy bay, thân xe hoặc chân động vật vẫn cung cấp thông tin phân lớp dù màu sắc và độ sáng thay đổi.

Bước 1: tính gradient. Ảnh RGB được đổi sang ảnh xám. Đạo hàm theo hai trục được xấp xỉ bằng hiệu giữa hai pixel lân cận, $g_x(x, y) = I(x + 1, y) - I(x - 1, y)$ và $g_y(x, y) = I(x, y + 1) - I(x, y - 1)$. Từ đó, độ lớn và hướng gradient là

$$m = \sqrt{g_x^2 + g_y^2}, \quad \theta = \text{atan2}(g_y, g_x) \bmod \pi. \quad (2)$$

Hướng được giới hạn trong $[0, 180)$ độ nên hai cạnh ngược chiều nhưng cùng phương được xem là giống nhau. Pixel có độ lớn gradient cao đóng góp nhiều hơn, còn vùng phẳng gần như không ảnh hưởng đến đặc trưng.

Bước 2: tạo histogram theo cell. Ảnh 32×32 được chia thành 8×8 cell, mỗi cell rộng 4×4 pixel. Miền hướng được chia thành 9 bin, mỗi bin rộng 20 độ. Một pixel không bị gán cứng vào một bin mà đóng góp tuyến tính cho hai bin gần nhất. Nếu vị trí hướng tính theo đơn vị bin là p , trọng số dành cho bin dưới và bin trên lần lượt là $m(1 - (p - \lfloor p \rfloor))$ và $m(p - \lfloor p \rfloor)$. Phép nội suy này làm vector thay đổi ít hơn khi hướng gradient nằm gần ranh giới giữa hai bin.

Bước 3: chuẩn hóa theo block. Bốn cell kề nhau tạo thành một block 2×2 . Các block trượt từng cell và có thể chồng lấn. Chuẩn hóa giúp hạn chế ảnh hưởng của độ tương phản cục bộ: cùng một đường biên có thể sáng hoặc tối hơn nhưng vẫn tạo ra phân bố hướng gần nhau. Với vector histogram của một block là v , chuẩn hóa L2-Hys gồm ba thao tác: chuẩn hóa L2, cắt các phần tử lớn hơn 0,2, rồi chuẩn hóa lại:

Với vector block v , hai bước L2-Hys được cài đặt như sau:

$$v' = \frac{v}{\sqrt{\|v\|_2^2 + \epsilon^2}}, \quad v'' = \frac{\min(v', 0.2)}{\sqrt{\|\min(v', 0.2)\|_2^2 + \epsilon^2}}. \quad (3)$$

Theo cấu hình trên, một ảnh có 7×7 vị trí block. Mỗi block chứa $2 \times 2 \times 9 = 36$ giá trị, vì vậy vector cuối có $7 \times 7 \times 36 = 1764$ chiều. Thứ tự các block trong vector vẫn giữ thông tin vị trí tương đối của cạnh. Tuy nhiên, HOG loại bỏ màu và chủ yếu mô tả hình dạng; đây là nguyên nhân hợp lý khiến phương pháp còn nhầm các lớp động vật có đường biên gần nhau. Các kiểm thử với cạnh ngang, cạnh dọc và ảnh hằng xác nhận hướng gradient, kích thước đầu ra và trường hợp độ lớn bằng 0.

3.2 Scale-Invariant Feature Transform (SIFT)

SIFT mô tả các vùng ảnh quanh những điểm có cấu trúc nổi bật, chẳng hạn góc, đốm hoặc phần giao nhau của nhiều cạnh [4]. Khác với HOG tạo một lưới cố định trên toàn ảnh, số điểm SIFT phụ thuộc vào nội dung từng ảnh. Mỗi điểm gồm vị trí, mức tỉ lệ, hướng chính và một vector mô tả cục bộ.

Bước 1: xây dựng không gian tỉ lệ. Vì ảnh CIFAR-10 chỉ có 32×32 pixel, cài đặt phóng ảnh xám lên 64×64 bằng cách lặp pixel. Ảnh sau đó được làm mờ với năm mức Gaussian $L(x, y, \sigma_i) = G(x, y, \sigma_i) * I(x, y)$, trong đó $\sigma_i = \sigma_0 k^i$, $\sigma_0 = 1$ và $k = 2^{1/3}$. Hiệu của hai mức liên tiếp tạo ảnh Difference of Gaussian (DoG):

$$D(x, y, \sigma_i) = L(x, y, \sigma_{i+1}) - L(x, y, \sigma_i). \quad (4)$$

DoG là phép xấp xỉ Laplacian of Gaussian với chi phí thấp hơn. Một pixel ứng viên phải là cực đại hoặc cực tiểu trong lân cận $3 \times 3 \times 3$, gồm tám điểm cùng mức và chín điểm ở mỗi mức liền kề.

Bước 2: lọc keypoint. Ứng viên có $|D| < 0,02$ bị loại vì độ tương phản thấp và dễ bị ảnh hưởng bởi nhiễu. Các điểm nằm dọc theo cạnh cũng không ổn định: chúng có thể xác định rõ theo phương vuông góc với cạnh nhưng không rõ theo phương còn lại. Chương trình dùng ma trận Hessian H của ảnh DoG và giữ điểm thỏa

$$\det(H) > 0, \quad \frac{\text{tr}(H)^2}{\det(H)} < \frac{(r+1)^2}{r}, \quad r = 10. \quad (5)$$

Các điểm còn lại được sắp theo trị tuyệt đối của đáp ứng DoG và chỉ giữ tối đa 64 điểm cho mỗi ảnh.

Bước 3: gán hướng. Trong vùng bán kính 6 pixel quanh keypoint, hướng gradient được gom vào histogram 36 bin. Bin có tổng độ lớn gradient cao nhất trở thành hướng chính θ_0 . Khi tạo mô tả, mọi hướng trong vùng lân cận đều được trừ θ_0 . Nhờ vậy, descriptor ít thay đổi khi nội dung ảnh quay quanh keypoint.

Bước 4: tạo descriptor 128 chiều. Một cửa sổ 16×16 quanh keypoint được chia thành 4×4 vùng con. Mỗi vùng tạo histogram 8 hướng, nên kích thước descriptor là $4 \times 4 \times 8 = 128$. Vector được chuẩn hóa L2, cắt ở ngưỡng 0,2 và chuẩn hóa lần nữa. Hai bước này giảm ảnh hưởng của gradient quá lớn do thay đổi chiếu sáng. Keypoint quá gần biên ảnh bị bỏ vì không đủ cửa sổ 16×16 .

Tạo đầu vào cho mô hình phân lớp. Mỗi ảnh có số descriptor khác nhau, trong khi SVM và Random Forest cần vector có độ dài cố định. Cấu hình Raw SIFT sắp các keypoint theo độ mạnh, nổi tối đa 64 descriptor và đếm số 0 nếu ảnh có ít hơn 64 điểm. Vector cuối có $64 \times 128 = 8192$ chiều. Cách làm này đơn giản nhưng vị trí thứ i trong vector không bảo đảm mô tả cùng một bộ phận vật thể giữa hai ảnh. Đây là hạn chế quan trọng khi dùng Raw SIFT trực tiếp cho phân lớp. Bản cài đặt cũng chỉ dùng một octave, không nội suy vị trí keypoint và không nội suy phiếu giữa các bin; vì vậy kết quả không được xem là tương đương với SIFT đầy đủ của Lowe.

3.3 Support Vector Machine (SVM)

SVM tuyến tính học một ma trận trọng số $W \in \mathbb{R}^{K \times D}$ (với K lớp và D chiều đặc trưng) để tính điểm số $s_j = W_j^\top x + b_j$ cho mỗi lớp j . Hàm mục tiêu kết hợp hinge loss đa lớp Crammer–Singer với điều chuẩn L2:

$$\mathcal{L} = \frac{1}{N} \sum_i \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1) + \frac{\lambda}{2} \|W\|_2^2. \quad (6)$$

Ý tưởng chính của SVM tuyến tính là tìm ra một siêu phẳng (hyperplane) trong không gian D chiều sao cho lề (margin) giữa các lớp là lớn nhất. Hằng số +1 trong hinge loss đóng vai trò biên an toàn: mô hình không chỉ yêu cầu lớp đúng y_i có điểm cao nhất, mà còn phải cao hơn mọi lớp sai ít nhất 1 đơn vị. Khi ràng buộc này bị vi phạm, hàm loss tạo ra gradient để đẩy trọng số W_{y_i} lên và kéo W_j xuống.

Thành phần điều chuẩn $\frac{\lambda}{2} \|W\|_2^2$ kiểm soát độ phức tạp của mô hình: giá trị λ lớn buộc các trọng số nhỏ, tạo ra biên quyết định mượt mà hơn và giảm nguy cơ overfitting. Ngược lại, λ quá nhỏ cho phép mô hình khớp sát dữ liệu huấn luyện nhưng dễ mất khả năng tổng quát hóa.

Mô hình được tối ưu bằng Gradient Descent ngẫu nhiên (SGD) theo mini-batch. Tại mỗi bước t , tốc độ học giảm theo $\eta_t = \eta_0 / \sqrt{t}$, giúp quá trình hội tụ ổn định hơn khi tiến gần đến điểm tối ưu. Gradient của hinge loss được tính trên toàn bộ mini-batch dưới dạng thao tác ma trận, tận dụng tối đa khả năng vector hóa của NumPy để đạt tốc độ thực thi cao mà không cần vòng lặp qua từng mẫu. Nhân dự đoán cuối cùng là lớp có điểm số lớn nhất: $\hat{y} = \arg \max_j s_j$.

3.4 Random Forest

Random Forest là một phương pháp học tập hợp (ensemble learning) kết hợp nhiều cây quyết định (Decision Tree) hoạt động độc lập để tạo ra dự đoán cuối cùng thông qua cơ chế bầu chọn đa số (majority voting).

Xây dựng từng cây (CART). Mỗi cây con được huấn luyện trên một tập dữ liệu bootstrap — tức là chọn ngẫu nhiên N mẫu có hoàn lại từ tập huấn luyện gốc. Do lấy có hoàn lại, trung bình chỉ khoảng 63,2% mẫu gốc xuất hiện trong mỗi tập bootstrap; phần còn lại (out-of-bag) có thể dùng để ước lượng sai số mà không cần tập kiểm định riêng. Tại mỗi nút, cây tìm cách chia dữ liệu thành hai nhóm con sao cho độ bất thuần (impurity) giảm nhiều nhất. Độ bất thuần Gini được định nghĩa:

$$G = 1 - \sum_{k=1}^K p_k^2, \quad (7)$$

trong đó p_k là tỷ lệ mẫu thuộc lớp k tại nút hiện tại. Khi $G = 0$, mọi mẫu đều cùng một lớp (nút thuần). Mục tiêu của mỗi phép chia là tối đa hóa mức giảm Gini giữa nút cha và hai nút con.

Đa dạng hóa bằng chọn đặc trưng ngẫu nhiên. Để giảm tương quan giữa các cây, tại mỗi nút phân nhánh, thuật toán chỉ xem xét ngẫu nhiên $\sqrt{d}$ chiều đặc trưng (thay vì toàn bộ d chiều). Nhờ cơ chế này, mỗi cây sẽ phát triển theo các hướng khác nhau, tạo nên sự đa dạng trong tập hợp (ensemble diversity). Sự kết hợp giữa Bootstrap Aggregating (Bagging) và chọn đặc trưng ngẫu nhiên chính là yếu tố then chốt giúp Random Forest chống overfitting hiệu quả.

Dự đoán. Khi suy luận, mỗi cây trong rừng đưa ra một nhân dự đoán riêng. Nhân cuối cùng được quyết định bằng bầu chọn đa số: $\hat{y} = \arg \max_k \sum_{t=1}^T \mathbf{1}[h_t(x) = k]$, trong đó h_t là cây thứ t và T là tổng số cây. Theo lý thuyết của Breiman, khi T đủ lớn, sai số tổng quát hóa của Random Forest hội tụ về một giới hạn trên xác định, phụ thuộc vào sức mạnh từng cây và mức tương quan trung bình giữa chúng [1].

4 Thiết lập thí nghiệm

Tất cả các thử nghiệm chính với Pixel, HOG và SIFT phẳng đều được thực hiện trên cùng tập dữ liệu chuẩn: 45.000 ảnh huấn luyện, 5.000 ảnh kiểm định và 10.000 ảnh kiểm tra. Trên mỗi loại đặc trưng, hai mô hình SVM tuyến tính và Random Forest được đánh giá để so sánh khách quan chất lượng biểu diễn. Mọi phép chia dữ liệu đều được phân tầng và sử dụng seed 42.

Mô hình SVM được huấn luyện với batch size là 256 ảnh. Tốc độ học ban đầu là 0,01 và $\lambda = 10^{-4}$. Mô hình Random Forest được thiết lập với mỗi nút kiểm tra ngẫu nhiên 16 ngưỡng trên $\sqrt{d}$ chiều. HOG dùng cell 4×4 , block 2×2 và 9 nhóm hướng.

Với $K = 10$ lớp, confusion matrix có phần tử $C_{ij} = \sum_n \mathbf{1}[y_n = i \wedge \hat{y}_n = j]$. Từ đó tính

$$P_k = \frac{C_{kk}}{\sum_i C_{ik}}, \quad R_k = \frac{C_{kk}}{\sum_j C_{kj}}, \quad F1_k = \frac{2P_k R_k}{P_k + R_k}. \quad (8)$$

Macro-F1 là trung bình $F1_k$ của mười lớp, do đó mỗi lớp có trọng số như nhau trong chỉ số tổng hợp.

Bảng 2: Kết quả trên tập kiểm tra.

Đặc trưng	Mô hình	N_{test}	Độ chính xác	Macro-F1
pixel	linear_svm	10000	0.3757	0.3751
pixel	random_forest	10000	0.4509	0.4462
hog	linear_svm	10000	0.5319	0.5305
hog	random_forest	10000	0.4673	0.4593
sift	linear_svm	10000	0.2292	0.2299
sift	random_forest	10000	0.1857	0.1433

5 Kết quả và thảo luận

Bảng 2 tổng hợp kết quả trên tập kiểm tra. Trên cùng 10.000 ảnh kiểm tra, HOG-SVM đạt độ chính xác 0,5364 và macro-F1 0,5351. Pixel-SVM chỉ đạt 0,3790 và 0,3763. Như vậy, HOG tăng lần lượt 15,74 và 15,88 điểm phần trăm. Hai mức tăng gần nhau cho thấy cải thiện không chỉ thể hiện ở tổng số ảnh đúng mà còn được duy trì khi lấy trung bình F1 trên mười lớp.

Về mặt tính toán, HOG đòi hỏi chi phí trích xuất đặc trưng lớn hơn (33,56 giây so với 0,93 giây của pixel). Tuy nhiên, vì biểu diễn HOG (1.764 chiều) nhỏ gọn hơn đáng kể so với ảnh màu phẳng (3.072 chiều), thời gian huấn luyện và suy luận của SVM được rút ngắn gọn. Nhìn chung, HOG đánh đổi chi phí tiền xử lý để đổi lấy độ chính xác vượt trội và một mô hình phân lớp nhẹ hơn ở giai đoạn sau.

Từ các kết quả trên, có thể giải thích sự khác biệt về độ chính xác giữa các phương pháp như sau:

Tại sao HOG + Linear SVM lại cho kết quả tốt nhất (53,19%)?


HOG trích xuất sự phân bố hướng của các gradient cục bộ, giúp nắm bắt rất tốt thông tin về *hình dáng* và *đường viền* của vật thể (ví dụ: bánh xe, cánh máy bay). Nhờ chia ảnh thành lưới không gian (8×8 cell), HOG giữ lại được cấu trúc tổng thể của đối tượng. Khi kết hợp với Linear SVM, đặc trưng này phát huy tối đa sức mạnh vì không gian đặc trưng HOG có số chiều lớn (1.764) và phân bố thưa, vốn là điều kiện lý tưởng để thuật toán SVM tìm ra siêu phẳng phân cách biên tối đa (max-margin hyperplane).

Tại sao Random Forest vượt trội hơn SVM trên đặc trưng Pixel (45,09% so với 37,57%)?

Đặc trưng Pixel (3.072 chiều) hoàn toàn không có thông tin không gian, chỉ là các giá trị màu sắc thô. Linear SVM áp dụng một trọng số tuyến tính cố định lên pixel, tương đương với việc khớp một "khuôn mẫu" (template) cứng nhắc, dẫn đến thất bại khi đối tượng thay đổi vị trí. Ngược lại, Random Forest là một mô hình phi tuyến. Bằng cách xây dựng các cây quyết định, nó có khả năng học các luật tổ hợp "if-else" phức tạp trên các điểm màu (ví dụ: góc trên xanh dương VÀ góc dưới xanh lá), giúp mô hình linh hoạt hơn trong việc bắt các mảng màu đặc trưng.

Tại sao SIFT phẳng lại tệ nhất (18% - 22%)?


SIFT trích xuất các điểm đặc trưng (keypoint) dựa trên cực trị cục bộ. Tuy nhiên, khi trải phẳng trực tiếp các vector này thành 8.192 chiều, mô hình đã vô tình đánh mất *tính căn chỉnh không gian* (spatial alignment). Chiều thứ 128 ở ảnh này có thể là lốp xe, nhưng ở ảnh khác lại là tai mèo. SVM và Random Forest đều yêu cầu các chiều đặc trưng phải đồng nhất về mặt ngữ nghĩa giữa các mẫu. Khi ngữ nghĩa bị xáo trộn, các mô hình học máy gần như không thể tìm ra quy luật phân lớp.



Hình 1: Đường hinge loss (trái) và các chỉ số theo lớp (phải) của HOG-SVM.

Theo Hình 1, phần lớn mức giảm của loss diễn ra trong những vòng huấn luyện đầu tiên; sau đó đường cong tiếp tục đi xuống chậm dần. Diễn biến này phù hợp với quy tắc giảm tốc độ học $\eta_t = \eta_0 / \sqrt{t}$. Đường loss vẫn có xu hướng giảm nhẹ về cuối, nên mô hình có thể chưa đạt điểm hội tụ hoàn toàn. Giả thuyết này cần được kiểm tra bằng tập kiểm định khi thay đổi số epoch hoặc λ ; tập kiểm tra không được dùng để chọn siêu tham số.

5.1 Phân tích theo lớp và ma trận nhầm lẫn



Hình 2: Ma trận nhầm lẫn của HOG-SVM trên 10.000 ảnh kiểm tra; mỗi lớp có 1.000 ảnh.

Hình 1 cho thấy *truck* và *automobile* có F1 cao nhất, lần lượt là 0,6600 và 0,6592. *Cat* có recall thấp nhất, chỉ 0,362; tiếp theo là *bird* với 0,387 và *dog* với 0,416. Trong Hình 2, hai lỗi lớn nhất là *dog*→*cat* (183 ảnh) và *cat*→*dog* (165 ảnh). Ngoài ra có 141 ảnh *airplane*→*ship*, 123 ảnh *cat*→*frog* và 121 ảnh *automobile*→*truck*. Quan sát các mẫu dự đoán sai cho thấy nhiều cặp nhầm lẫn có đường biên hoặc hình dáng gần nhau ở độ phân giải thấp. Đây là bằng chứng phù hợp với giả thuyết rằng HOG chưa biểu diễn đủ thông tin về màu và bề mặt.

6 Kết luận

Báo cáo đã xây dựng và kiểm chứng một quy trình phân loại ảnh CIFAR-10 từ dữ liệu đầu vào đến kết quả dự đoán, sử dụng hoàn toàn các phương pháp thị giác máy tính truyền thống được cài đặt từ đầu. Trong các thử nghiệm trên toàn bộ dữ liệu, HOG kết hợp SVM tuyến tính đạt độ chính xác cao nhất và vượt trội hơn đáng kể so với pixel thô. Random Forest cho thấy ưu thế trên đặc trưng pixel nhờ khả năng phi tuyến tính, nhưng lại kém hơn SVM khi đặc trưng đã được thiết kế tốt (như HOG). Ma trận nhầm lẫn cho thấy lỗi tập trung ở các lớp động vật có hình dáng gần nhau, nổi bật là *cat* và *dog*. Tuy nhiên, đánh giá chỉ dùng một seed nên chưa đủ để đưa ra kết luận chắc chắn về tính khái quát.

Tài liệu tham khảo

- [1] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [2] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2005.
- [3] Alex Krizhevsky. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.
- [4] David G. Lowe. Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2):91–110, 2004.